




SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
MERCADO, CASES E TENDÊNCIAS	26
O QUE VOCÊ VIU NESTA AULA?	27
REFERÊNCIAS.....	28

O QUE VEM POR AÍ?

Bem-vindos e bem-vindas! Nosso curso terá foco no objetivo de todos os projetos que envolvem o uso de modelos de **Machine Learning (ML)**, que é colocá-los em produção. Porém, esse processo costuma ser desafiador, pois não basta criar um modelo de ML, é preciso lidar com todas as partes adjacentes do modelo de ML, processo no qual muitas empresas acabam falhando.

O **MLOps (Machine Learning Operations)** emergiu como uma resposta às complexidades inerentes à implantação e manutenção de modelos de ML em produção. Empresas como Google e Microsoft realizaram estudos sobre o tema que derivaram em artigos que destacaram os desafios e propuseram soluções para integrar práticas de **DevOps** ao ciclo de vida de modelos de ML.

HANDS ON

Nesta aula, serão abordados conceitos e práticas essenciais para a construção de um pipeline de ML completo, desde o treinamento do modelo até a sua disponibilização em produção. O foco aqui será na apresentação dos princípios de MLOps, como versionamento, orquestração de workflows e automação, visando criar um fluxo de trabalho robusto e escalável. Ao final, veremos como vamos integrar esses componentes em um projeto prático, simulando um cenário real de implantação de modelos de ML.

SAIBA MAIS

O cenário tecnológico atual é marcado por uma rápida transformação digital, impulsionada, em grande parte, pela Inteligência Artificial (IA) e pelo Aprendizado de Máquina, ou Machine Learning (ML), que é um subcampo da IA. O uso de modelos de IA e ML deixou de ser uma exclusividade de laboratórios de pesquisa de universidades e passou a ocupar um lugar central nas estratégias de negócios de diversas empresas e setores.

Esta mudança é resultado de diversos fatores convergentes que serão apresentados durante esta aula.

Linha do tempo da IA e ML

1950s – Métodos estatísticos

Os métodos estatísticos começam a ser descobertos e refinados, formando a base matemática para o ML e outros avanços futuros em IA.

Em 1943, Warren McCulloch e Walter Pitts publicaram um [artigo](#) intitulado “A Logical Calculus of the Ideas Immanent in Nervous Activity”, no qual propuseram o primeiro modelo matemático de um neurônio artificial. Este modelo era baseado em lógica booleana e era capaz de realizar cálculos simples, marcando o início do que hoje conhecemos como Redes Neurais Artificiais (RNAs).

1950s – Primeiras pesquisas em ML

Em 1956 o termo "Inteligência Artificial" é usado por John McCarthy durante a [conferência](#) de Dartmouth, marcando formalmente o início da pesquisa em IA.

Em 1958, o [Perceptron](#) foi introduzido por Frank Rosenblatt, na publicação “The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain”. O Perceptron foi uma implementação prática de uma RNA, introduzindo o conceito de pesos associados às conexões entre neurônios e um mecanismo de aprendizado supervisionado, permitindo que o sistema ajustasse os pesos para se adequar aos dados de treinamento.

1960s – Árvore de Decisão e Multilayer Perceptron

Em 1963, Morgan e Sonquist introduzem as **Árvores de Decisão** como ferramenta estatística no [artigo](#) “Problems in the Analysis of Survey Data and a Proposal”. Ainda em 1969, o conceito de **Multilayer Perceptron (MLP)** foi introduzido no [livro](#) “Perceptrons por Marvin Minsky e Seymour Papert”.

1970s – "AI Winter" e backpropagation

A década de 70 é marcada pelo "AI Winter", nesse período houve uma redução drástica na pesquisa acadêmica no tema de IA, que ocorreu devido ao ceticismo sobre a eficácia de modelos de IA e a falta de avanços práticos na aplicação dessas tecnologias.

Em 1974, Paul Werbos introduziu o conceito de **backpropagation** em sua tese de [doutorado](#) na Universidade de Harvard. Ele propôs usar esse método para treinar RNAs, mas sua ideia não ganhou popularidade na época devido à falta de recursos computacionais e interesse no campo de pesquisa.

1980s – Backpropagation e a volta das RNAs

O backpropagation é trazido de volta ao cenário pelos pesquisadores David E. Rumelhart, Geoffrey E. Hinton (Prêmio Nobel de Física em 2024) e Ronald J. Williams, por meio de uma [publicação](#) na revista “Nature”. O artigo revitaliza esse campo de pesquisa em RNAs e estabelece uma base sólida para pesquisas na área.

Em 1989, Yann LeCun e sua equipe, demonstraram a eficácia de uma **Rede Neural Convolucional (CNNs)** treinada com backpropagation para reconhecimento de dígitos manuscritos no [artigo](#) “Backpropagation Applied to Handwritten Zip Code Recognition”.

1990s – CRISP-DM e Big Data

Em 1996 a SPSS (depois adquirida pela IBM) cria o **CRISP-DM (Cross-Industry Standard Process for Data Mining)**, um framework que organiza o ciclo de vida de projetos de **Mineração de Dados**. Diferente da Ciência de Dados, a Data Mining possuía um [escopo](#) de atuação e ferramentas utilizadas menos amplo.

Em 1997 surge o termo **Big Data** no [artigo](#) Application-Controlled Demand Paging for Out-of-Core Visualization, de Michael Cox e David Ellsworth. O artigo é

sobre os desafios de visualização de dados no contexto da NASA, os autores mencionaram a expressão para descrever o problema de lidar com grandes volumes de dados que não cabiam na memória dos computadores.

2000s – Deep Learning e computação em nuvem

Em 2006, o termo cloud computing ganha popularidade com o lançamento do [Amazon EC2](#), [S3](#) e [SQS](#) pela Amazon Web Services (AWS), permitindo a democratização do acesso a recursos computacionais e de armazenamento de dados sob demanda.

Ainda em 2006, o conceito de **Deep Learning** foi apresentado no [artigo](#) “A fast learning algorithm for deep belief nets”, pelo pesquisador Geoffrey E. Hinton. O artigo descreve o treinamento de RNAs profundas, ou seja, RNAs com várias camadas ocultas (Figura 1).




Figura 1 - Diagrama de Deep Learning com duas camadas ocultas e múltiplas saídas
Fonte: James et al. (2003)

2010s – Popularização do ML, Deep Learning e MLOps

Em 2010, o Big Data é consolidado como um pilar da transformação digital, com ferramentas como **Hadoop** e **Spark** facilitando o processamento distribuído de grandes volumes de dados. Ainda em 2010, a [biblioteca](#) **scikit-learn** desempenhou

um papel fundamental na democratização e popularização de ML com o seu lançamento. Ela rapidamente se tornou uma das bibliotecas mais utilizadas para ML em Python.

A arquitetura **AlexNet**, criada por Alex Krizhevsky, Ilya Sutskever e Geoffrey E. Hinton em 2012, revolucionou o campo de Deep Learning ao vencer o desafio de reconhecimento de imagens do Image Net LargeScale Visual Recognition Challenge (ILSVRC). A AlexNet reduziu significativamente o erro em tarefas de classificação de imagens de aproximadamente 26% para 15%, e essa arquitetura ainda trouxe inovações consideráveis com o uso de **GPUs** para acelerar o treinamento e introdução de **ReLU (Rectified Linear Unit)** como função de ativação, melhorando a convergência, e técnicas como **dropout** para evitar overfitting.

Em outubro de 2012, a Harvard Business Review publicou o [artigo](#) "Data Scientist: The Sexiest Job of the 21st Century", escrito por Thomas H. Davenport e D.J. Patil. O artigo destacou a crescente demanda por cientistas de dados e como essa profissão se tornaria essencial nas empresas modernas.

Em 2015, o [artigo](#) Hidden Technical Debt in Machine Learning Systems foi apresentado no NIPS (Neural Information Processing Systems) pelo time de engenharia da Google, que destacou os desafios de gerenciar sistemas de ML em produção. Apesar de não ter aparecido o termo **MLOps (Machine Learning Operations)** no artigo, esse termo é um marco para esse paradigma.

Em 2017, o [artigo](#) "Attention is All You Need" introduz a arquitetura **Transformer**, revolucionando o Processamento de Linguagem Natural (NLP) e pavimentando o caminho para IA Generativa.

2020s – IA Generativa e consolidação do ML

Em 2020, modelos como **GPT-3** (OpenAI) e [BERT](#), mostram a força da IA generativa, permitindo geração de texto e processamento de linguagem de alta qualidade.

Em 2022, modelos como [StableDiffusion](#) tornam a IA Generativa acessível a tarefas criativas, como geração de imagens e vídeos.

No ano de 2023, ferramentas como **ChatGPT** popularizam a IA entre o público geral, tornando-se amplamente utilizadas como um assistente virtual e automação de tarefas como pode ser visto na figura a seguir.




Figura 2 - Print do Google Trends para ChatGPT
Fonte: Google Trends (2024)

Desafios relacionados aos sistemas de ML em produção

Como foi evidenciada na timeline de eventos relacionados a IA e ML, o artigo “Hidden Technical Debt in Machine Learning Systems”, de 2015 – o qual foi um marco no de sistemas de IA e ML em produção – apresentou os desafios relacionados aos sistemas de ML devido à sua complexidade. Nesse artigo os autores argumentam que, embora o ML seja uma ferramenta poderosa para criar sistemas preditivos, é importante não ignorar os custos de manutenção desse tipo de sistema no longo prazo. O artigo introduz o conceito de "dívida técnica" para sistemas de ML, destacando riscos inerentes a esse tipo de sistema, como a dependência de dados instáveis, e “anti-patterns” que aumentam a complexidade, dificultam a manutenção, reduzem a flexibilidade para mudanças no sistema e elevando risco de ocorrência de falhas. Veja a figura a seguir:




Figura 3 - Complexidade de um sistema de ML e suas partes adjacentes
 Fonte: Sculley et al. (2015).

Outra publicação importante no tema de ML em produção foi o “Software Engineering for Machine Learning: A Case Study”, de 2019, com autoria de pesquisadores da área de P&D da Microsoft. Nesse artigo, os autores apresentam práticas de engenharia de software adaptadas para integrar ML em processos de desenvolvimento de sistemas em larga escala, como práticas relacionadas à CI/CD no contexto de ML. Os autores também apresentaram uma proposta de um workflow com nove etapas para integrar ML no desenvolvimento de software, incluindo coleta de dados, limpeza, engenharia de features, treinamento, avaliação, implantação e monitoramento.




Figura 4 - Fluxo de nove etapas do workflow de ML
 Fonte: Amershi et al. (2019)

Os autores também identificam os desafios de sistemas de ML relacionados à complexidade no gerenciamento e versionamento de dados, dificuldades de modularidade entre componentes de ML, e algumas diferenças fundamentais entre software tradicional e sistemas de ML, como feedback loops ocultos e propagação de erros. Ainda apresentam um modelo inicial de maturidade de processos de ML, inspirado no **Capability Maturity Model (CMM)**, avaliando níveis de definição de objetivos, documentação, automação, rastreamento e melhoria contínua.

Paradigma MLOps para sistema de ML em produção

O artigo “Machine Learning Operations (MLOps): Overview, Definition, and Architecture” de 2023, aborda o paradigma de MLOps, que busca resolver os desafios associados à automação e operacionalização de sistemas de ML. O MLOps é um paradigma que combina conceitos, boas práticas e cultura de desenvolvimento para projetar, implementar, monitorar, implantar e escalar sistemas de ML. O artigo explora o objetivo do MLOps – que é uma prática de engenharia que integra disciplinas de ML, engenharia de software (especialmente DevOps) e engenharia de dados – que agiliza a entrega de sistemas de ML com qualidade para o ambiente de produção de forma eficiente e sustentável. Veja na figura a seguir:




Figura 5 - Interseção de disciplinas no paradigma MLOps
Fonte: Kreuzberger et al. (2023)

Ainda nesse artigo, os autores conduziram uma pesquisa mista, incluindo revisão de literatura, análise de ferramentas e entrevistas com especialistas, para identificar princípios, componentes técnicos, cargos/funções necessários e uma arquitetura para sistemas de ML.

Boas práticas e componentes técnicos no MLOps

Um princípio pode ser entendido como uma verdade, um valor ou um guia de comportamento. No contexto de MLOps, um princípio serve como orientação de como as coisas devem ser realizadas com o paradigma de MLOps, que está diretamente relacionado ao conceito de “boas práticas”.

Dada essa definição, os autores identificaram nove princípios necessários para a implementação do MLOps e respectivas componentes técnicas. A figura a seguir ilustra esses princípios e os vincula aos componentes com os quais estão associados.




Figura 6 - Princípios do MLOps X componentes técnicas
Fonte: Kreuzberger et al. (2023)

Princípios do MLOps

- **CI/CD (P1)**: automação de integração contínua, entrega contínua e implantação contínua, garantindo feedback rápido sobre o sucesso ou falha de etapas como build, teste, entrega e deploy.
- **Orquestração de workflow(P2)**: coordenação de tarefas em pipelines de ML usando gráficos acíclicos direcionados (DAGs), definindo ordem de execução e dependências.
- **Reprodutibilidade (P3)**: habilidade de reproduzir experimentos de ML e obter os mesmos resultados.
- **Versionamento (P4)**: versionamento de dados, modelos e códigos para garantir rastreabilidade e reprodutibilidade.
- **Colaboração (P5)**: facilitação da colaboração em equipe, promovendo uma cultura de trabalho comunicativa e reduzindo silos entre funções.

- **Treino contínuo de ML e avaliação (P6):** retraining contínuo baseado em novos dados, com suporte de componentes automatizados de monitoramento e avaliação.
- **Tracking de metadados de ML (P7):** rastreamento de metadados para cada tarefa do pipeline, incluindo parâmetros, métricas de desempenho e linhagem de modelos.
- **Monitoramento contínuo (P8):** monitoramento contínuo de dados, código, infraestrutura e desempenho de modelos para detectar erros e mudanças.
- **Feedback Loops (P9):** múltiplos ciclos de feedback para integrar insights de avaliações de qualidade ao processo de desenvolvimento.

Componentes técnicos do MLOps:

- **Componente de CI/CD (C1, usa os princípios P1, P6, P9):** responsável pela automação do build, teste, entrega e deploy de artefatos, aumentando a produtividade e confiabilidade.
- **Repositório de código fonte (C2, usa os princípios P4, P5):** repositório para versionamento do código de treino, inferência e aplicação, permitindo colaboração entre desenvolvedores.
- **Componente de orquestração de workflow (C3, P2, P3, P6):** orquestrador de tarefas do pipeline de ML, gerenciando a sequência e interdependência de processos.
- **Feature Store (C4, usa os princípios P3, P4):** sistema central para armazenar features, com bancos offline para experimentação e on-line para produção.
- **Infraestrutura de treino de modelo de ML (C5, usa o princípio P6)** infraestrutura escalável para treinar modelos, incluindo recursos como CPUs, GPUs e memória.
- **Model Registry (C6, usa os princípios P3, P4):** repositório central para armazenar modelos treinados e seus metadados.

- **Store de metadados de ML(C7, usa os princípios P4, P7):** armazena metadados sobre experimentos, como parâmetros, métricas e linhagem de modelos.
- **Componente de Model Serving (C8, usa o princípio P1):** componente para servir modelos, configurado para inferência on-line (tempo real) ou batch.
- **Componente de monitoramento (C9, usa os princípios P8, P9):** monitora continuamente o desempenho de modelos e da infraestrutura, gerando insights para ajustes ou retraining.

Esses princípios e componentes ilustram como o MLOps combina automação, rastreabilidade e colaboração para entregar sistemas de ML robustos e escaláveis.

Funções no MLOps

Entendo os princípios e relação com as componentes técnicas, passamos agora a identificar as funções necessárias para colocar o MLOps em prática. O MLOps é um processo que é composto por um grupo interdisciplinar, e a interação entre diferentes funções é fundamental para projetar, gerenciar, automatizar e operar um sistema de ML em produção.




Figura 7 - Funções e suas interseções que contribuem para o paradigma do MLOps

Fonte: Kreuzberger et al. (2023)

As funções necessárias são as seguintes:

- **Business Stakeholder (ou Product Owner, Project Manager):** o stakeholder do negócio define os objetivos de negócio a serem alcançados com ML e cuida da comunicação com a área de negócio, por exemplo, apresentando o retorno sobre o investimento (ROI) gerado com um produto de ML.
- **Arquiteto de solução:** o arquiteto de soluções projeta a arquitetura e define as tecnologias a serem utilizadas.
- **Cientista de Dados:** o cientista de dados traduz o problema de negócios em um problema de ML implementando e testando modelos.
- **Engenheiro de Dados:** o engenheiro de dados cria e gerencia pipelines de engenharia de dados e seus respectivos recursos, garantindo a ingestão adequada de dados nos bancos de dados.
- **Engenheiro de Software:** o engenheiro de software usa padrões de design de software, boas práticas de desenvolvimento de código e práticas recomendadas para transformar o problema de ML em um produto bem projetado.
- **Engenheiro de DevOps:** o engenheiro de DevOps preenche a lacuna entre o desenvolvimento e as operações e garante a automação adequada de CI/CD, orquestração do fluxo de trabalho de ML, implantação do modelo em produção e monitoramento.
- **Engenheiro de ML/MLOps:** o engenheiro de ML (ou engenheiro de MLOps) combina aspectos de várias funções e, portanto, tem conhecimento multidisciplinar. Essa função incorpora habilidades de cientistas de dados, engenheiros de dados, engenheiros de software, engenheiros de DevOps e engenheiros de backend. Essa função cria e opera a infraestrutura de ML, gerencia os pipelines de ML automatizados, implanta modelos em produção, e monitora tanto o modelo quanto a infraestrutura de ML.

Arquitetura

Baseados nos princípios, componentes e funções, os autores propõem uma arquitetura de MLOps “end-to-end”, projetada para ser agnóstica (ou seja, independente de tecnologias específicas), possibilitando combinar ferramentas open source e soluções corporativas. Essa arquitetura contempla:

- Os passos iniciais de um produto MLOps, que definem o escopo do projeto e suas metas;
- A pipeline de engenharia de features, incluindo a ingestão de dados na feature store/banco de dados, etapa fundamental para preparar e organizar os dados;
- A fase de experimentação, em que modelos são criados e avaliados;
- O pipeline automatizado de ML até a disponibilização (serving) do modelo em produção.

A ideia dos autores foi oferecer um roteiro flexível para profissionais e pesquisadores, permitindo escolher as ferramentas e frameworks mais adequados às suas necessidades e ilustrando como integrar cada parte do processo de ML, do início do projeto até a entrega do modelo, conforme ilustrado na figura a seguir:




Figura 8 - Arquitetura e fluxo de trabalho MLOps “end-to-end” com componentes e respectivas funções

Fonte: Kreuzberger et al. (2023)

Desafios para adoção do paradigma de MLOps

Os autores do artigo encontraram vários desafios para adotar o paradigma de MLOps, eles foram identificados após conduzir uma revisão de literatura, revisão de ferramentas e realização de entrevistas. Esses desafios foram organizados nas categorias de desafios **organizacionais**, de sistema de ML e operacionais.

Desafios organizacionais:

- **Cultura e mindset:** é necessário mudar o enfoque de um modelo puramente orientado à criação de algoritmos para uma visão de produto, envolvendo todo o ciclo de desenvolvimento.
- **Falta de profissionais e habilidades necessárias:** há escassez de profissionais qualificados em áreas como arquitetura, engenharia de dados, engenharia de ML e DevOps. Além disso, muitas formações em ciência de dados ainda não incluem os fundamentos de MLOps.
- **Trabalho em equipe:** a colaboração interdisciplinar é essencial, mas as equipes muitas vezes operam em silos e com diferentes terminologias, o que dificulta a comunicação e a adoção de um processo de MLOps.
- **Convencimento de stakeholders:** é preciso evidenciar para os tomadores de decisão que amadurecer em MLOps e adotar um enfoque orientado a produtos traz benefícios claros para o negócio.

Desafios relacionados aos sistemas de ML:

- **Escalabilidade e recursos:** o volume e a variabilidade dos dados (e, consequentemente, a demanda por recursos de CPU, RAM e GPU) dificultam o planejamento da infraestrutura. Com isso, é necessário desenvolver o sistema para lidar com picos de uso.

Desafios operacionais:

- **Complexidade técnica:** manter sistemas de ML em produção envolve múltiplos componentes de software e hardware, demandando robusta automação para orquestrar e monitorar todo o pipeline.
- **Retraining e automação:** com a chegada constante de novos dados, é necessário treinar modelos de forma repetitiva. Esse processo intensifica a necessidade de automação e boas práticas de governança.
- **Geração de artefatos e versionamento:** versionar dados, código e modelos é fundamental para garantir reprodutibilidade e robustez, mas gera complexidade em termos de controle e gestão.

- **Diagnóstico de falhas:** problemas podem ocorrer em diferentes partes da infraestrutura e do software, tornando a identificação da causa raiz desafiadora devido ao grande número de atores e componentes envolvidos.

Níveis de maturidade de MLOps

Por volta de janeiro de 2020, tanto a Google quanto a Microsoft publicaram seus **modelos de maturidade para MLOps**, delineando níveis que descrevem a evolução das práticas de treinamento e implantação de modelos de ML em produção.

A Google introduziu um modelo com três níveis de maturidade em seu documento MLOps: Continuous delivery and automation pipelines in machine learning. Simultaneamente, a Microsoft apresentou seu modelo de maturidade de MLOps, detalhado no Machine Learning operations maturity model.

Essas publicações têm sido fundamentais para orientar organizações na implementação de práticas eficazes de MLOps, promovendo maior automação, eficiência e escalabilidade nos processos de ML.

Modelo da Google

A Google apresenta um modelo de maturidade de MLOps estruturado em três níveis principais (níveis 0,1 e 2), que descreve a evolução do processo de ML de operações manuais e isoladas, até pipelines totalmente automatizados e integrados. Este modelo enfatiza a necessidade de automação e integração contínua para alcançar eficiência, reprodutibilidade e escalabilidade. A seguir, detalhamos cada nível:

Nível 0: Processo manual

No nível inicial, o processo de desenvolvimento de modelos de ML é totalmente manual, e há pouca integração entre as diferentes etapas. Equipes de ciência de dados e operações trabalham de forma independente, o que limita a colaboração e a reprodutibilidade.

Características:

- **Treinamento e implantação manuais:** todas as etapas, desde a coleta de dados até o deploy, são feitas manualmente.

- **Falta de rastreabilidade:** não há versionamento ou rastreo eficiente de código, dados ou modelos.
- **Escalabilidade limitada:** modelos são difíceis de ajustar ou reproduzir em diferentes ambientes.

Desafios:

- Esse nível enfrenta problemas com reprodutibilidade, erros manuais e dificuldades de manutenção, tornando o processo ineficiente para casos de uso em larga escala.




Figura 9 - Etapas manuais de ML para servir o modelo como um serviço de previsão com nível 0 de maturidade

Fonte: Blog de arquitetura da Google (2024)

Nível 1: Automação de pipeline

Neste estágio, partes do pipeline de ML são automatizadas, reduzindo o esforço manual necessário e promovendo maior consistência e eficiência no processo. Esse é o primeiro passo para integrar práticas de DevOps ao ciclo de vida de ML.

Características:

- **Automação parcial:** treinamento, validação e deploy começam a ser automatizados usando pipelines básicos.
- **Integração Contínua (CI):** código e dados são integrados em sistemas de controle de versão, garantindo maior rastreabilidade.

- **Entrega Contínua (CD):** modelos podem ser implantados em ambientes de produção automaticamente após validação.

Vantagens:

- Melhor colaboração entre as equipes;
- Processos mais consistentes e rastreáveis;
- Redução de erros manuais.

Desafios:

- Embora tenha avanços significativos, ainda há dependência de intervenções manuais em partes do pipeline, como ajustes de dados e monitoramento pós-implantação.




Figura 10 - Automação de pipeline de ML com nível 1 de maturidade
Fonte: Blog de arquitetura da Google (2024).

Nível 2: Automação total

No nível mais avançado, todos os aspectos do ciclo de vida de ML são automatizados e integrados. Isso inclui desde a coleta de dados até o monitoramento de modelos em produção e o retraining automático com novos dados.

Características:

- **Pipelines de Automação Completa:** incluem ingestão de dados, validação, treinamento, validação de modelos, deploy e monitoramento.
- **Monitoramento Contínuo:** modelos em produção são monitorados para verificar desempenho e detectar desvios (drift).
- **Retraining Automático:** modelos são atualizados automaticamente com base em novos dados ou métricas de desempenho.
- **Feedback Loops:** Dados de produção alimentam diretamente o pipeline, permitindo iterações contínuas.

Vantagens:

- Escalabilidade para gerenciar múltiplos modelos e grandes volumes de dados;
- Alta reprodutibilidade, reduzindo erros e inconsistências;
- Redução do tempo de deploy para novos modelos e melhorias.




Figura 11 - Pipeline de ML e CI/CD automatizados
Fonte: Blog de arquitetura da Google (2024)

O pipeline de ML com nível de maturidade 1, consiste nas seguintes componentes:

1. **Desenvolvimento e experimentação:** testa novos algoritmos e modelos, gerando código-fonte para o pipeline.
2. **Integração contínua do pipeline:** compila o código e gera artefatos prontos para implantação.
3. **Entrega contínua do pipeline:** implanta os artefatos no ambiente de produção.
4. **Disparo automatizado:** executa automaticamente o pipeline em resposta a gatilhos ou cronogramas de agendamento de execução.
5. **Entrega contínua do modelo:** implanta o modelo treinado como serviço de previsão.
6. **Monitoramento:** coleta estatísticas do desempenho do modelo e aciona novas execuções quando necessário.

O modelo de maturidade de MLOps da Google fornece uma estrutura clara para a evolução de operações de aprendizado de máquina, com ênfase na automação e integração contínuas. Enquanto o nível inicial se concentra na organização básica, os níveis mais avançados integram processos como monitoramento contínuo e retraining automático, possibilitando que organizações operem em escala e com alta eficiência. Este modelo é particularmente útil para equipes que buscam alinhar ciência de dados, engenharia de software e operações em um ciclo de vida de ML robusto e sustentável.

Modelo da Microsoft

O modelo de maturidade MLOps da Microsoft esclarece os princípios e práticas de MLOps, promovendo a melhoria contínua no desenvolvimento e operação de sistemas de ML em produção. Ele pode ser usado para avaliar o progresso, identificar lacunas e planejar incrementos realistas no amadurecimento dos processos de ML. O mesmo contém cinco níveis de maturidade técnica.

Nível 0: “No MLOps”

Nesse nível de maturidade, o gerenciamento do ciclo de vida de modelos de ML é realizado de forma completamente manual. As equipes são desconectadas, tornando difícil a colaboração, e as implementações de modelos são trabalhosas e

ineficientes. Os sistemas existentes são tratados como "caixas-pretas", com pouco ou nenhum feedback durante ou após a implantação. As construções e implantações de código são feitas manualmente, assim como os testes de modelo e aplicação, e não há rastreamento centralizado de desempenho do modelo. Todo o processo de treinamento do modelo também é manual.

Nível 1: “DevOps but no MLOps”

Conhecido como "DevOps, mas sem MLOps", a automação começa a ser introduzida em aspectos específicos, como builds e testes de código da aplicação, tornando as implementações menos dolorosas. No entanto, ainda existe uma dependência significativa das equipes de dados para cada novo modelo. Apesar de alguns avanços, os resultados permanecem difíceis de rastrear ou reproduzir, e há pouco feedback disponível sobre o desempenho dos modelos em produção.

Nível 2: “Automated Training”

Nesse nível, o foco se desloca para o treinamento automatizado. O ambiente de treinamento é totalmente gerenciado e rastreável, facilitando a reprodução de modelos. O treinamento do modelo é automatizado, e há um rastreamento centralizado do desempenho do treinamento. No entanto, as implementações ainda são manuais, embora com menos atritos, e então surge uma gestão básica dos modelos.

Nível 3: “Automated Model Deployment”

É introduzida a implantação automatizada de modelos. Nesta fase, as implementações se tornam automáticas e com baixa fricção, e há rastreabilidade completa desde o deploy do modelo até os dados originais utilizados em seu treinamento. Todo o ambiente é gerenciado de ponta a ponta, abrangendo as fases de treinamento, teste e produção. Além disso, testes A/B são integrados para avaliar o desempenho do modelo, e o rastreamento centralizado de desempenho do treinamento é plenamente operacional. O sistema como um todo está bem mais integrado e eficiente.

Nível 4: “Full MLOps Automated Operations”

Esse nível é marcado pela automação completa das operações de MLOps. Neste estágio, todo o sistema é altamente automatizado e monitorado, com os

sistemas de produção fornecendo informações contínuas para melhorias. Em alguns casos, essas melhorias são feitas automaticamente com a introdução de novos modelos. O sistema atinge um nível próximo de zero downtime, com treinamento, teste e monitoramento de modelos completamente automatizados. Métricas centralizadas detalhadas garantem total visibilidade sobre o desempenho do modelo e do sistema como um todo, promovendo um ciclo contínuo de melhoria e otimização.

Conteúdo do curso

Nesta disciplina teremos aulas sobre Docker, Flask, Streamlit e uma aula final juntando todos os conceitos vistos para criar um pipeline de ML.

Quanto aos componentes técnicos, temos a infraestrutura de treinamento (C5), um repositório de modelo (C6), orquestração de workflow (C3) e componentes de serving (C8). Mesmo de forma simplificada e local, essas partes representam um fluxo end-to-end de ML, desde o treino até o uso prático do modelo.




Figura 12 - Desenho de arquitetura da solução para aula final
Fonte: elaborado pelo autor (2024)

MERCADO, CASES E TENDÊNCIAS

Veja a apresentação sobre Engenharia de MLOps na AWS, no re:Invent de 2023. O [vídeo](#) apresenta uma introdução abrangente ao MLOps na AWS, destacando os desafios de operacionalizar modelos de ML e as melhores práticas para integrar ciência de dados e operações de TI.

Neste material são abordados tópicos como a necessidade de colaboração entre equipes diversas (engenheiros de dados, cientistas de dados e DevOps), governança e segurança de dados, e ferramentas como o AWS SageMaker, que automatizam pipelines, monitoram modelos e garantem conformidade. Além disso, explica as diferenças entre DevOps e MLOps, enfatizando a importância de processos bem estruturados e a evolução das organizações em um modelo de maturidade que vai da experimentação inicial à escalabilidade completa.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, exploramos os fundamentos de ML em produção, com foco nos desafios e nas soluções proporcionadas pelo paradigma de MLOps. Discutimos os princípios básicos de reprodutibilidade e versionamento, a orquestração de workflows e o uso de componentes técnicos como infraestrutura de treinamento, registro de modelos e servidores para inferência.



REFERÊNCIAS

AMAZON WEB SERVICES. **Amazon EC2 Beta**. Disponível em: <https://aws.amazon.com/pt/blogs/aws/amazon_ec2_beta/>. Acesso em: 17 jan. 2025.

AMAZON WEB SERVICES. **Amazon Simple Queue Service (SQS)**. Disponível em: <https://aws.amazon.com/pt/blogs/aws/amazon_simple_q/>. Acesso em: 17 jan. 2025.

AMAZON WEB SERVICES. **Amazon Web Services Launches**. Disponível em: <<https://press.aboutamazon.com/2006/3/amazon-web-services-launches>>. Acesso em: 17 jan. 2025.

AMERSHI, S.; BEGEL, A.; BIRD, C.; DELINE, R.; GALL, H.; KAMAR, E.; NAGAPPAN, N.; NUSHI, B.; ZIMMERMANN, T. **Software Engineering for Machine Learning: A Case Study**. *Proceedings of the 41st International Conference on Software Engineering (ICSE)*, p. 291-300, 2019. Disponível em: <https://www.microsoft.com/en-us/research/uploads/prod/2019/03/amershi-icse-2019-Software-Engineering-for-Machine-Learning.pdf>. Acesso em: 17 jan. 2025.

CLOUD GOOGLE. **MLOps: Continuous Delivery and Automation Pipelines in Machine Learning**. Disponível em: <<https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning?hl=pt-br>>. Acesso em: 17 jan. 2025.

CRISP-DM. **IBM SPSS Modeler CRISP-DM Guide**. Disponível em: <https://www.ibm.com/docs/pt-br/SS3RA7_18.5.0/nl/pt/BR/pdf/ModelerCRISPDM.pdf>. Acesso em: 17 jan. 2025.

DARTMOUTH. **Artificial Intelligence (AI) Coined at Dartmouth**. Disponível em: <<https://home.dartmouth.edu/about/artificial-intelligence-ai-coined-dartmouth>>. Acesso em: 17 jan. 2025.

DEVLIN, J.; CHANG, M.; LEE, K.; TOUTANOVA, K. **BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding**. *arXiv preprint*, 2018. Disponível em: <<https://arxiv.org/abs/1810.04805>>. Acesso em: 17 jan. 2025.

HBR. **Data Scientist: The Sexiest Job of the 21st Century**. Disponível em: <<https://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century>>. Acesso em: 17 jan. 2025.

HINTON, G. E.; OSINDERO, S.; TEH, Y. **A Fast Learning Algorithm for Deep Belief Nets**. *Neural Computation*, v. 18, p. 1527-1554, 2006. Disponível em: <<https://www.cs.toronto.edu/~fritz/absps/ncfast.pdf>>. Acesso em: 17 jan. 2025.

HISTORY OF DATA SCIENCE. **AI Winter: The Highs and Lows of Artificial Intelligence**. Disponível em: <<https://www.historyofdatascience.com/ai-winter-the-highs-and-lows-of-artificial-intelligence/>>. Acesso em: 17 jan. 2025.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R.; TAYLOR, J. **An Introduction to Statistical Learning, with Applications in Python**. Springer Texts in Statistics, 2023. Disponível em: https://doi.org/10.1007/978-3-031-38747-0_1. Acesso em: 17 jan. 2025.

KREUZBERGER, D.; KÜHL, N.; HIRSCHL, S. **Machine Learning Operations (MLOps): Overview, Definition, and Architecture**. *IEEE Access*, v. 11, p. 31866-31877, 2023. <https://ieeexplore.ieee.org/document/10081336>. Acesso em: 17 jan. 2025.

LECUN, Y.; BOSER, B.; DENKER, J. S.; HENDERSON, D.; HOWARD, R. E.; HUBBARD, W.; JACKEL, L. D. **Backpropagation Applied to Handwritten Zip Code Recognition**. *AT&T Bell Laboratories*, Holmdel, NJ, 1989. Disponível em: <https://ieeexplore.ieee.org/document/6795724>. Acesso em: 17 jan. 2025.

MCCULLOCH, W. S.; PITTS, W. **A Logical Calculus of the Ideas Immanent in Nervous Activity**. *Bulletin of Mathematical Biophysics*, v. 5, p. 115-133, 1943. Disponível

em:<<https://www.cs.cmu.edu/~./epxing/Class/10715/reading/McCulloch.and.Pitts.pdf>>. Acesso em: 17 jan. 2025.

MICROSOFT AZURE. **MLOps Maturity Model**. Disponível em: <<https://learn.microsoft.com/en-us/azure/architecture/ai-ml/guide/mlops-maturity-model>>. Acesso em: 17 jan. 2025.

MINSKY, M.; PAPERT, S. **Perceptrons: An Introduction to Computational Geometry**. Expanded edition. Cambridge: MIT Press, 1988. 258 p. ISBN 0-262-63111-3.

MORGAN, James N.; SONQUIST, John A. **Problems in the Analysis of Survey Data, and a Proposal**. *Journal of the American Statistical Association*, v. 58, n. 302, p. 415-434, jun. 1963. Disponível em:<<http://www.jstor.org/stable/2283276>>. Acesso em: 17 jan. 2025.

PINECONE. **ImageNet and the Evolution of Image Search**. Disponível em: <<https://www.pinecone.io/learn/series/image-search/imagenet/>>. Acesso em: 17 jan. 2025.

ROMBACH, R.; BLATTMANN, A.; LORENZ, D.; ESSER, P.; OMMER, B. **High-Resolution Image Synthesis with Latent Diffusion Models**. *arXiv preprint*, 2022. Disponível em:<<https://arxiv.org/abs/2112.10752>>. Acesso em: 17 jan. 2025.

ROSENBLATT, F. **The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain**. *Psychological Review*, v. 65, n. 6, p. 386-408, 1958. Disponível em:<<https://www.ling.upenn.edu/courses/cogs501/Rosenblatt1958.pdf>>. Acesso em: 17 jan. 2025.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. **Learning Representations by Back-Propagating Errors**. *Nature*, v. 323, p. 533–536, 1986. DOI: <https://www.nature.com/articles/323533a0>. Acesso em: 17 jan. 2025.

SCIKIT-LEARN. **About Scikit-Learn 1.5.** Disponível em: <<https://scikit-learn.org/1.5/about.html>>. Acesso em: 17 jan. 2025.

SCULLEY, D.; HOLT, G.; GOLOVIN, D.; DAVYDOV, E.; PHILLIPS, T.; EBNER, D.; CHAUDHARY, V.; YOUNG, M.; CRESPO, J. F.; DENNISON, D. **Hidden Technical Debt in Machine Learning Systems.** In: *Advances in Neural Information Processing Systems (NIPS)*, 2015. Disponível em: <<https://proceedings.neurips.cc/paper/2015/file/86df7dcfd896fcdf2674f757a2463eba-Paper.pdf>>. Acesso em: 17 jan. 2025.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. **Attention Is All You Need.** *Advances in Neural Information Processing Systems*, v. 30, 2017. Disponível em: <<https://arxiv.org/abs/1706.03762>>. Acesso em: 17 jan. 2025.

WERBOS, P. J. **Beyond Regression: New Tools for Prediction and Analysis in the Behavioral Sciences.** *Thesis (PhD)* — Harvard University, 1974. Disponível em: <https://www.researchgate.net/publication/35657389_Beyond_regression_new_tools_for_prediction_and_analysis_in_the_behavioral_sciences>. Acesso em: 17 jan. 2025.

PALAVRAS-CHAVE

Machine Learning, Sistemas de Machine Learning, MLOps.

EMEND

The background is a dark blue field filled with numerous small, light blue dots. Overlaid on this are several large, wavy, translucent lines in shades of blue, yellow, and red. These lines flow from the left side towards the right, creating a sense of motion. Scattered throughout the composition are various geometric shapes: a circle containing the number '7' in the upper center, a small circle on the left, an 'X' shape in the lower left, a small circle below it, and a hexagon in the bottom right corner.

POSTECH