

O arquivo "Tech Challenge Obesity Notebook (1).pdf" (e seu correspondente "Tech Challenge Obesity Notebook.pdf") é um **modelo robusto e bem estruturado** que abrange as etapas essenciais de um projeto de Data Analytics, atendendo à maior parte dos requisitos técnicos da Fase 4.

A validação do arquivo indica que ele já fornece a fundação necessária para todos os entregáveis, mas as **"Notas Finais e Recomendações"** presentes no próprio *notebook* apontam as áreas de melhoria crítica para atingir a profundidade e a excelência exigidas no *Tech Challenge*.

Abaixo está a validação detalhada do arquivo com base nas fontes e requisitos:

1. Pipeline de Machine Learning e Feature Engineering

O *notebook* estabelece uma base sólida para a construção da *pipeline*, essencial para a consistência dos dados.

Aspecto	Status no Notebook (e Fontes)	Melhorias Recomendadas (Pelo Próprio Notebook/Fontes)
Transformação Reprodutível	Implementa classes personalizadas (ImcCalculator e DataFrameSelector) e utiliza transformadores do Scikit-learn (OneHotEncoder, OrdinalEncoder, MinMaxScaler).	Aplicar SimpleImputer para dados numéricos/categóricos para garantir resiliência, mesmo sem NaNs aparentes.
Criação de Variáveis (Feature Engineering)	Calcula o Índice de Massa Corporal (IMC) a partir de Weight e Height, uma <i>feature</i> chave para o problema de obesidade.	Não há menção imediata a técnicas de tratamento de <i>outliers</i> como winsorization , mas o próprio notebook sugere incluir uma seção de tratamento de <i>outliers</i> (e.g., boxplots).
Codificação	Utiliza corretamente OrdinalEncoder para colunas ordinais e OneHotEncoder para categóricas (como recomendado para evitar que o classificador aprenda erroneamente que um dado é "maior que o outro").	Incluir uma célula Markdown que justifique a escolha entre OneHotEncoding para variáveis nominais e OrdinalEncoding para variáveis com ordem.

2. Modelagem e Avaliação (Assertividade > 75%)

O notebook foca em modelos supervisionados de classificação e utiliza métodos avançados para validação, como exigido.

Aspecto	Status no Notebook (e Fontes)	Melhorias Recomendadas (Pelo Próprio Notebook/Fontes)
---------	-------------------------------	---

Treinamento e Otimização	Importa e utiliza modelos como XGBClassifier, RandomForestClassifier e LogisticRegression. Implementa Validação Cruzada (K-Fold) e Grid Search para ajuste de hiperparâmetros, garantindo que o modelo generalize bem.	Testar e registrar explicitamente o desempenho com múltiplos modelos (ex: SVM, KNN, Regressão Logística) para justificar a escolha final do modelo.
		Adicionar uma tabela comparativa final detalhada, incluindo acurácia, precisão macro, recall macro e F1 macro para todos os modelos testados. Adicionar o <i>plot</i> das Curvas ROC (Receiver Operating Characteristic) para cada classe, o que é fundamental para avaliar a capacidade discriminatória do modelo.
Métricas de Desempenho	Importa métricas cruciais como <code>accuracy_score</code> , <code>classification_report</code> , <code>confusion_matrix</code> e <code>roc_auc_score</code> . A acurácia é a métrica principal (> 75%).	

3. Deploy e Modularidade

O requisito de **deploy com Streamlit** é endereçado com preparação dos artefatos.

Aspecto	Status no Notebook (e Fontes)	Melhorias Recomendadas (Pelo Próprio Notebook/Fontes)
Artefatos Salvos	O modelo (<code>model_pipeline.joblib</code>) e a ordem das colunas (<code>col_order.csv</code>) são salvos usando <code>joblib</code> e Pandas .	Criar a seção dedicada (por exemplo, um arquivo <code>utils.py</code>) para mover as classes de transformação, garantindo a modularidade.
Aplicação Streamlit e Docker	Contém código base para o aplicativo Streamlit e o <code>Dockerfile</code> , demonstrando como carregar os artefatos salvos e configurar a interface de entrada de dados (widgets).	Documentar claramente como o Streamlit lê <code>col_order.csv</code> e o modelo. Fornecer instruções passo a passo para rodar o ambiente com Docker e Streamlit Cloud.

4. Visão Analítica (Dashboard) e Storytelling

O projeto exige que a análise seja apresentada com uma **visão de negócio** para a equipe médica.

Aspecto	Status no Notebook (e Fontes)	Melhorias Recomendadas (Pelo Próprio Notebook/Fontes)
Análise Exploratória de Dados (EDA)	Inclui EDA básica, como a distribuição da variável <i>target</i> (<code>Obesity_level</code>) e estatísticas de IMC por classe.	Aprofundar a EDA: Adicionar gráficos mais elaborados, como <i>violinplots</i> e <i>pairplots</i> controlados, e visualizações da distribuição de variáveis críticas (Age, Weight, Height, IMC) estratificadas pelo nível de obesidade.

Comunicação e Insights	Importa shap, sugerindo análise de importância de variáveis (Feature Importance).	Adicionar uma seção Markdown ("Storytelling e visão de negócio") para explicar a importância clínica das principais variáveis e relacionar os achados do modelo (ex.: usando SHAP) com recomendações práticas para a equipe médica.
Documentação Final	O notebook instrui que o entregável final (o PDF) deve incluir screenshots da aplicação Streamlit e do painel analítico (dashboard), além de documentar todas as decisões de modelagem.	Concretizar o Storytelling ao traduzir os resultados técnicos do modelo (matriz de confusão, precisão por classe) em implicações de negócio (o que o hospital deve fazer).

Em resumo, o "Tech Challenge Obesity Notebook (1).pdf" é um ponto de partida técnico **altamente funcional e completo** (contendo os principais códigos e estruturas de ML) e deve ser validado positivamente, mas as melhorias sugeridas por ele mesmo – **robustez da pipeline de pré-processamento, comparação exaustiva de modelos e a formalização da comunicação de negócios** – são essenciais para transformá-lo em um entregável de excelência para a Fase 4.