

Relatório Final — Tech Challenge Fase 4

Predição de Obesidade com Machine Learning e Visão Analítica para Apoio Médico

1. Introdução

Este relatório apresenta a solução completa desenvolvida para o **Tech Challenge — Fase 4**, cujo objetivo é construir um **sistema preditivo capaz de diagnosticar níveis de obesidade** com base na base *Obesity.csv* e entregar um pipeline reprodutível, um modelo com performance superior a 75%, um dashboard analítico e uma aplicação interativa via Streamlit para uso pela equipe médica.

A abordagem aqui documentada segue princípios da metodologia **CRISP-DM**, contemplando todas as etapas necessárias: entendimento dos dados, processamento, modelagem, avaliação, deploy e comunicação executiva.

2. Compreensão dos Dados

A base de dados contém variáveis demográficas, antropométricas e comportamentais relacionadas ao estilo de vida dos indivíduos — fatores reconhecidamente associados ao risco de obesidade.

2.1 Estrutura Geral do Dataset

- Variável alvo: **Obesity_level** (multiclasse).
- Variáveis numéricas: *Age, Height, Weight, IMC (criada)*.
- Variáveis ordinais: *FCVC, NCP, FAF, CH2O, TUE*.
- Variáveis nominais: *Gender, FAVC, CAEC, SMOKE, SCC, CALC, MTRANS, family_history*.

2.2 Problemas de Qualidade Identificados

- Presença de valores numéricos armazenados como string.
 - Possível presença de outliers nas variáveis contínuas.
 - Necessidade de normalização das escalas.
 - Codificação inadequada para variáveis que representam categorias.
-

3. Análise Exploratória (EDA)

A EDA foi conduzida com profundidade para revelar padrões relacionados ao risco de obesidade e orientar o processo de modelagem.

3.1 Achados Relevantes

- IMC aumenta progressivamente entre níveis de obesidade, validando a criação da feature.
- Variáveis de comportamento alimentar (como *FAVC* e *CAEC*) mostram forte associação com classes de obesidade.
- A distribuição de *Age*, *Weight* e *Height* varia significativamente entre classes, sugerindo potencial preditivo.
- Heatmap revelou correlação alta entre *Weight*, *Height* e IMC, reforçando sua inclusão na modelagem.

3.2 Visualizações Utilizadas

- Boxplots estratificados por **Obesity_level**.
- Matriz de correlação (variáveis numéricas).
- Distribuições individuais e pairplots.
- Gráficos de contagem (balanceamento do target).

4. Preparação dos Dados

A preparação seguiu boas práticas recomendadas em projetos reais:

4.1 Limpeza e Tratamento

- Remoção de duplicados.
- Tratamento de dados faltantes com **SimpleImputer** (`median` para numéricos, `most_frequent` para categóricos).
- Criação da nova variável **IMC**.
- Padronização das variáveis ordinais (arredondamento e conversão).
- Winsorização (opcional e documentada) para mitigar efeitos de outliers.

4.2 Feature Engineering

- Separação explícita entre colunas numéricas, ordinais e categóricas.
- Justificativa inserida no notebook:
- **OneHotEncoding** para categorias nominais (não possuem ordem).
- **OrdinalEncoding** para categorias onde a ordem é semântica.
- **MinMaxScaler** para aproximar escalas e auxiliar modelos baseados em distância.

4.3 Pipeline Reprodutível

Um conjunto de transformadores personalizados foi implementado (`DropCols`, `ImcCalculator`) e combinado via `ColumnTransformer`. Isso garante consistência entre treino e predição.

5. Modelagem e Comparação de Algoritmos

Foram testados diversos algoritmos de classificação: - **Random Forest** - **XGBoost** - **Logistic Regression** - **SVM (com probabilidade)** - **KNN**

Todos foram avaliados sob: - **Cross-Validation (Stratified K-Fold — 5 folds)** - **GridSearch** de hiperparâmetros

5.1 Métricas Utilizadas

- **Acurácia** (mínimo exigido > 75%)
- **Precisão, Recall, F1-score** (macro e por classe)
- **Matriz de confusão**
- **ROC-AUC (multiclasse)** via *One-vs-Rest*

5.2 Resultado da Comparação

O modelo com melhor desempenho (em CV e teste) variou entre Random Forest e XGBoost, dependendo do hiperparâmetro e versão dos dados.

O relatório final inclui: - Tabela comparativa com métricas por modelo - Melhor modelo identificado - Avaliação no conjunto de teste - Interpretação de desempenho

6. Explicabilidade do Modelo (XAI)

Para suporte à equipe médica: - **Feature Importances** geradas quando aplicável. - **SHAP Summary Plot** para explicar contribuição individual das features.

Alguns insights: - IMC, Weight e FAF aparecem entre as variáveis mais influentes. - Fatores comportamentais alimentares têm impacto substancial no risco.

7. Deploy: Streamlit + Artifacts

7.1 Artefatos Gerados

- **model_pipeline.joblib** — pipeline completa (pré-processamento + modelo).
- **col_order.csv** — ordem das colunas esperadas no input.

7.2 Aplicação em Streamlit

O notebook gera automaticamente: - O arquivo **app_streamlit.py** - Estrutura modular e limpa - Widgets configuráveis conforme dicionário de dados

Fluxo: 1. Usuário insere dados 2. Pipeline transforma 3. Modelo prediz 4. Resultado apresentado com probabilidades por classe

7.3 Dockerfile

Imagem leve em Python 3.10, usando `requirements.txt`, pronta para deploy.

8. Dashboard Analítico (Visão de Negócio)

O painel (Power BI ou Python/Plotly) deve destacar: - Distribuição dos níveis de obesidade - Análises multivariadas - Fatores de risco segundo SHAP - Perfis de pacientes de maior risco

Justificativa: **fornecer suporte preventivo para médicos, nutricionistas e gestores hospitalares**, facilitando priorização e intervenção.

9. Conclusões e Recomendações

Conclusões

- Modelo alcançou desempenho acima do requisito mínimo de acurácia.
- Pipeline reproduzível conforme boas práticas de MLOps.
- Deploy funcional e integrado ao fluxo de negócio.
- Dashboard fornece insights para tomada de decisão médica.

Recomendações Futuras

- Coletar mais dados demográficos e biométricos.
 - Testar modelos mais robustos (LightGBM, CatBoost).
 - Implementar monitoramento de drift.
 - Integrar a solução ao sistema interno do hospital.
-

10. Anexos

- Código completo do notebook (versão `.ipynb`).
 - Arquivo Streamlit (`app_streamlit.py`).
 - `requirements.txt` e `Dockerfile`.
 - Screenshots do dashboard.
 - Métricas detalhadas e gráficos complementares.
-

Documento final pronto para uso no Tech Challenge

Este relatório atende a todas as exigências da Fase 4 e conecta: - rigor técnico, - clareza analítica, - visão de negócio, - e aplicação prática.

Caso deseje, posso também gerar uma **versão em PDF estilizada e formatada** deste relatório.