

ANA RAQUEL

POSTECH

DATA ANALYTICS

DEEP & REINFORCEMENT LEARNING

AULA 02

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	17
REFERÊNCIAS.....	18

EMSE

O QUE VEM POR AÍ?

Você sabia que as redes neurais conseguem identificar e distinguir imagens, assim como nós (seres humanos)? Nessa aula aprenderemos como funciona a arquitetura das **Redes Neurais Convolucionais (CNN)**! As CNNs emergiram do estudo do córtex visual cerebral e têm sido utilizadas no reconhecimento de imagens desde a década de 80. Então, vamos aprender como funciona a arquitetura dessa rede e entender o motivo dela ser tão poderosa?



HANDS ON

Vamos aprender a criar um classificador de imagens? Nas próximas aulas, veremos o passo a passo de como criar uma arquitetura de redes convolucionais aplicando reconhecimento de imagens.

O código desta aula você encontra aqui: [código da aula 02](#).

Além disso, também temos a [base de dados da aula 02](#) e [imagens para teste](#).

EMANUELA

SAIBA MAIS

ENTENDENDO A INSPIRAÇÃO DAS REDES NEURAIS CONVOLUCIONAIS

Assim como aprendemos nas redes neurais multicamadas, as CNNs também são inspiradas em fatores biológicos. Em 1958 e 1959, David H. Hubel e Torton Wiesel realizaram uma série de experimentos com gatos, na qual proporcionaram o aprendizado sobre a estrutura do córtex visual.




Figura 1 - Experimento realizado no córtex visual em um gato.

Fonte: Anh Nguyen (2019)

Hubel e Wiesel descobriram que os neurônios do córtex visual de um gato **são ativados juntos quando expostos a algumas linhas ou curvas**. Inspirado no córtex visual, saber distinguir diferentes imagens é possível quando **identificamos e comparamos diferentes características em cada ponto específico na imagem**. Eles também notaram que alguns neurônios têm campos receptivos maiores e reagem a padrões mais complexos que são combinações dos padrões de nível inferior. Essas observações levaram à ideia de que os neurônios de nível superior são baseados nas

saídas dos neurônios vizinhos de nível inferior. Esta poderosa arquitetura é capaz de detectar todos os tipos de padrões complexos em qualquer área do campo visual.

Como o computador identifica imagens

Você deve estar se perguntando: “Como o computador consegue identificar uma imagem”, certo? Sabemos que trabalhar com dados não estruturados pode ser uma tarefa não tão simples. As entradas das redes CNNs são, basicamente, imagens, o que torna o seu input de dados diferenciado. Sabemos que o computador entende números, correto? Pois bem, as redes neurais basicamente recebem uma **matriz de pixels da imagem como entrada da rede**.

Existem os tipos de imagens em escala de cinza (grayscale) e as imagens coloridas (RGB). Essas imagens são compostas por pixels que variam entre 0 a 255, mostrando a intensidade de cores. A imagem a seguir, por exemplo, está representada por uma matriz 2D, onde cada posição da imagem é composta por elementos que variam de 0 (preto) a 255 (branco). Quanto mais próximo de 255, mais clara é a cor em escala de cinza.




Figura 2 - Pixels de uma imagem grayscale.

Fonte: elaborado pela autora (2023)

Já as imagens em escala colorida (RGB), são representadas por uma matriz 3D, combinando as cores vermelho, verde e azul. O propósito principal do sistema

RGB é a reprodução de cores em dispositivos eletrônicos como monitores de TV, computadores, mídias digitais e celulares em geral.




Figura 3 - Pixels de uma imagem rgb.

Fonte: elaborado pela autora (2023)

Arquitetura das redes neurais convolucionais

Quando pensamos em redes CNN, a **camada convolucional** é a mais importante e que faz total diferença entre as redes neurais comuns. Os neurônios na primeira camada convolucional não estão conectados a cada pixel na imagem de entrada, assim como a rede que aprendemos na última aula, mas apenas a pixels em campos respectivos. Desta forma, cada neurônio da segunda camada convolucional está conectado apenas a neurônios localizados dentro de um pequeno retângulo na primeira camada. Elas são responsáveis pela etapa de aprendizagem das partes da imagem como um todo.





Figura 4 - Camadas NN com campos receptivos locais retangulares.
Fonte: Aurélien Geron (2019)

Para entendermos de forma simples o funcionamento das redes convolucionais, utilizaremos um exemplo clássico nos estudos das redes neurais: imagine que a rede neural convolucional será treinada para classificar dígitos escritos a mão em números de 0 até 9. Cada pessoa possui uma caligrafia única e nem sempre as escritas são iguais. Um grande desafio para a rede, certo?



Figura 5 - Amostra de dígitos escritos à mão.
Fonte: Analytics Vidhya (2021)

Vamos pegar um exemplo do dígito zero (0). Imagine que a figura 5 será a entrada da rede e a arquitetura da rede tem a estrutura da figura 6.



Fonte: Neto, 2017 - Aprendizado profundo: conceitos, técnicas e estudo de caso de análise de imagens com Java

Figura 6 - Arquitetura de redes neurais convolucionais.
Fonte: Francisco Gerardo Medeiros Neto, et. al. (2017)

Observe que temos a primeira camada chamada de **convolução**, que é responsável pelo papel de "**detector de atributos**". Essa etapa vai mapear a região de uma imagem para, posteriormente, termos um "**mapa de atributos**". Funciona basicamente como um filtro, na qual chamamos de **kernel** na rede. O filtro nada mais é do que a multiplicação de matrizes, e esse processo é realizado diversas vezes por toda a imagem recebida.




Figura 7 - Camadas convolucionais.
Fonte: elaborado pela autora (2023)

Ao realizar a convolução, o mapa de atributos começa a aprender as partes importantes para identificar a composição da imagem (assim como David H. Hubel e Torton Wiesel concluíram que os neurônios do córtex visual de um gato são ativados

juntos quando são expostos a algumas linhas ou curvas). Cada pixel será identificado dentro da etapa de convolução, passando pelo filtro kernel movido por um multiplicador, realizando assim a transformação da imagem em um formato compactado.

Essa transformação acontece para a rede mapear quais são os pontos “chaves” que caracterizam essa imagem e armazena em uma representação dimensionalizada para passar para a próxima etapa de convolução da rede.

O multiplicador dessa etapa de convolução se chama “**stride**” (**deslocamento**) (normalmente com o valor = 1), cuja principal função é realizar a **transformação** da imagem. Toda essa transformação irá resultar em uma imagem com uma dimensão menor.




Figura 8 - Deslocamento com stride nas imagens.

Fonte: <https://indoml.com>.

É comum adicionar zeros ao redor das imagens de entrada, para que uma camada tenha a mesma altura e largura da camada anterior. Esse comportamento é chamado de **padding** na rede. O objetivo dele é manter a dimensionalidade da imagem. Na configuração das redes neurais convolucionais, podemos parametrizar o padding como “**same**” ou “**valid**”.

- **Valid** significa que a rede não criará a borda de zeros na imagem e pode ignorar algumas linhas e colunas na parte inferior e direita da imagem de entrada.
- **Same** significa que será criada a borda de zeros na imagem.




Figura 9 - Padding.
Fonte: elaborado pela autora (2023)




Figura 10 – Padding 2
Fonte:Fonte: Aurélien Géron (2019)

Imagine que a imagem do dígito zero entre na primeira camada convolucional, com um tamanho de 32x32x3, ou seja, a altura e largura são iguais a 32, e o 3 significa a escala de cores da imagem, que no caso está em grayscale, então temos pixels que variam de 0 a 255.



Figura 11 - Exemplo da camada convolucional.
Fonte: elaborado pela autora (2023).

Logo em seguida, essa imagem passa pelo kernel (filtro) e convolve a imagem, tornando-a em uma dimensão menor de 5X5X3.




Figura 12 - Exemplo da camada convolucional.
Fonte: elaborado pela autora (2023).

Talvez você esteja se perguntando: "e por que esses filtros dão certo?". Bem, os pesos dos neurônios podem ser representados por uma imagem menor. Durante o

treinamento, a CNN encontra os filtros mais úteis para sua tarefa de aprender a combiná-los em padrões mais complexos.




Figura 13 - Exemplo da camada convolucional com kernel.
Fonte: elaborado pela autora (2023).




Figura 14 - Mapa de ativação criado na etapa de filtro do kernel.
Fonte: elaborado pela autora (2023).

A cada medida que realizamos essas extrações de características das imagens, adicionamos novos mapas de filtros. Exemplo: se são 6 filtros de 5x5, teríamos 6 mapas de ativação.




Figura 15 - Mapas de ativação.
Fonte: elaborado pela autora (2023)

Entre as camadas de mapa de atributos, vamos ter uma **função de ativação** para realizar a classificação das imagens. Nossa, então, rede torna-se uma sequência de camadas de convolução, intercaladas por funções de ativação. A função de ativação ReLU é muito utilizada para treinar imagens devido ao seu comportamento de não ativar todos os neurônios ao mesmo tempo (isso traz mais performance para a rede).




Figura 16 - Mapas de ativação entre funções de ativação.
Fonte: elaborado pela autora (2023)

Em seguida, temos a camada de **pooling**. Seu objetivo é subamostrar (ou seja, diminuir) a imagem de entrada para reduzir a carga computacional, o uso da memória e o número de parâmetros (limitando o risco de overfitting). A operação **max pooling** retira o maior elemento de determinada região da matriz (imagem). Em seguida é realizado um novo cálculo de stride (assim como na convolução). A principal motivação dessa operação no modelo, é de diminuir sua variância a pequenas alterações e também de reduzir a quantidade de parâmetros treinados pela rede.




Figura 17 - Max e AVG Polling.
Fonte: elaborado pela autora (2023)




Figura 18 - O pooling máximo em profundidade pode ajudar a CNN a aprender qualquer invariância
Fonte: Aurélien Géron (2019)

As arquiteturas CNN típicas basicamente empilham algumas camadas convolucionais com a função de ativação ReLU, depois uma camada pooling, em seguida outras camadas convolucionais com a função de ativação ReLU, depois outra camada pooling, e assim por diante. À medida em que a rede vai avançando, a imagem vai ficando cada vez menor e mais profunda (graças aos mapas de atributos nas camadas convolucionais).




Figura 19- Arquitetura típica de CNN.
Fonte:Fonte: Aurélien Géron (2019)

O QUE VOCÊ VIU NESTA AULA?

Nessa aula, você aprendeu o que são as redes neurais convolucionais e como funciona a arquitetura dessa rede que lida com imagens.

O que achou do conteúdo? Conte-nos no Discord! Estamos disponíveis na comunidade para fazer networking, tirar dúvidas, enviar avisos e muito mais. Participe!

EMENDAS

REFERÊNCIAS

Deep Learning Book. [s.d.]. Disponível em: <<https://www.deeplearningbook.com.br/>>.

Acesso em: 23 out. 2023.

GÉRON, Aurélien. Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow, 2nd Edition. [s.l.]: O'Reilly Media, Inc., 2019.

Why choose Keras? Keras. [s.d.]. Disponível em: <https://keras.io/why_keras/>.

Acesso em: 23 out. 2023.

PALAVRAS-CHAVE

Palavras-chave: Convolução, Pooling, Convolutional Layer, Kernel, Stride, ReLU.

EMSE

The background is a dark blue field filled with numerous small, light blue dots, resembling a starry sky. Overlaid on this are several large, flowing, wavy lines in shades of teal, blue, and yellow. These lines create a sense of movement and depth. Scattered throughout the composition are various geometric shapes: a thin vertical line, a circle containing the number '7', a small circle, a cross, a small circle, and a hexagon.

POSTECH