

ANA RAQUEL

POSTECH

DATA ANALYTICS

DEEP & REINFORCEMENT LEARNING

AULA 03

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	12
REFERÊNCIAS.....	13

EMSE

O QUE VEM POR AÍ?

Você já parou para pensar sobre como nós, humanos, podemos utilizar algum aprendizado passado para tentar aprender algo novo? Por exemplo, mesmo nunca tendo aprendido a andar em uma moto antes, poderíamos tentar aproveitar algum aprendizado obtido quando éramos crianças e aprendemos a andar de bicicleta, tal como aprender a ter equilíbrio, por exemplo. É esse tipo de “aproveitamento” de aprendizado que as redes neurais de transferência de aprendizagem aplicam. Nessa aula, você vai aprender como funciona essa transferência de aprendizagem e como podemos ganhar tempo e performance com esses tipos de redes. Vamos lá?

HANDS ON

Nessa aula, você irá aprender a aplicar a arquitetura MobileNetV2 na rede que criamos para classificar cães e gatos e melhorar significativamente a performance do modelo. Essa rede foi criada pelo Google e sua ideia consiste em criar convoluções profundas. Não se esqueça que nossa aula começa na parte final desse notebook, pois é uma melhoria da nossa rede neural criada na aula 2. A aula inicia em: criando uma rede neural transfer learning com MobileNetV2.

O código desta aula você encontra aqui: [códigos da aula 03](#).

Temos a [base de dados utilizada nas aulas](#), a [base de dados utilizada para validação](#) e [as imagens para teste](#).

SAIBA MAIS

TRANSFER LEARNING

Nas últimas aulas, aprendemos que a tarefa de treinar uma rede neural não é tão simples, pois as redes possuem muitas camadas de neurônios e o trabalho de identificar uma nova imagem, por exemplo, pode ser bem custoso, já que é necessário milhares de imagens com diversas variações para a rede aprender de forma inteligente e eficaz. Esse tipo de aprendizagem exige um alto custo computacional e tempo de processamento.

Já pensou se existissem redes neurais já “prontas”, ou seja, já treinadas para aplicarmos a certas resoluções de problemas? Algumas empresas grandes, como o Google, Microsoft e IBM criam modelos pré-treinados onde podemos aproveitar o aprendizado de algumas features e aplicar nos nossos modelos que possuem um certo propósito parecido com essas redes já prontas.




Figura 1 - Diferença entre transfer learning e deep learning do princípio.
Fonte: Sky Engine AI (2023)

Podemos fazer uma analogia bem simples para compreensão do funcionamento dessa rede neural. Imagine a seguinte situação: uma pessoa que nunca comeu comida japonesa pede conselhos para uma pessoa que gosta muito desse tipo de culinária e já conhece os melhores lugares da região para dar dicas de qual é a melhor refeição, melhores restaurantes, preços e assim por diante. Aqui, a pessoa que já conhece bem a culinária japonesa está fazendo uma **transferência de**

conhecimento para uma pessoa que ainda não conhece, passando um certo “norte” de como realizar os próximos passos e conseguir experimentar a culinária japonesa. É assim que as redes neurais transfer learning funcionam! Essas redes já possuem um certo conhecimento estabelecido no conceito de deep learning, que pode ser consumido por outra rede sem a necessidade de tantos inputs de dados, facilitando assim o consumo de modelos de deep learning. Aliás, nem tudo precisa ser criado exatamente do zero, já que temos muitos trabalhos desenvolvidos no mercado e que podem ser reutilizados para auxiliar em outros aprendizados.

O Keras já possui classes especializadas para os seguintes modelos de deep learning treinados com o conjunto de dados ImageNet, conforme é possível checar no próprio [site do ImageNet](#).

- Xception;
- VGG16;
- VGG19;
- ResNet50;
- InceptionV3;
- InceptionResNetV2;
- MobileNet;
- MobileNetV2;
- DenseNet;
- NASNet.

ENTENDENDO TRANSFER LEARNING

Você lembra, na aula de redes convolucionais, que tivemos um grande desafio ao tentar classificar imagens de cães e gatos criando uma deep learning convolucional do zero? A rede até chegou em uma acurácia relativamente boa, mas poderia melhorar, e um dos pontos que poderia dar um certo ganho de performance seria aumentar o número de amostras de imagens disponíveis na base de treinamento do algoritmo.




Figura 2 - Diferença entre treinamento e teste do modelo de classificação de cães e gatos
 Fonte: elaborado pela autora (2023)

Perceba que, ao analisar o gráfico da nossa rede neural convolucional, até a 10ª época de processamento, os conjuntos de treinamento e validação pareciam andar juntos em questão de performance, mas esse comportamento foi se perdendo ao longo do processamento da rede, resultando em 71% de acurácia para validação e 84% para treinamento.

CORRIGINDO O OVERFITTING DAS REDES NEURAIS CONVOLUCIONAIS

Existem muitas formas de reduzir o overfitting em deep learning, tal como técnicas de regularização, batch normalization e também **aumentar o tamanho da base de treinamento dos dados**. Parece muito, mas 1000 imagens podem ser muito pouco para ensinar uma rede neural a aprender os detalhes e particularidades de características de imagens. Se utilizarmos por exemplo uma rede neural que já foi treinada com milhares de imagens de amostra, seu desempenho pode melhorar muito. Dentro do treinamento de redes neurais convolucionais, no início da extração de características de imagens, alguns passos podem se tornar “padrão” em qualquer tipo de imagem, tal como identificação de bordas, por exemplo. As camadas iniciais e centrais são aplicadas à aprendizagem por transferência, e as últimas camadas são

apenas recicladas. A rede faz uso dos dados rotulados da tarefa na qual foi treinado. Se tivermos uma rede neural transfer learning que já saiba identificar (e muito bem) esse tipo de comportamento, podemos ganhar performance, dar um upgrade no nosso modelo e conseguir classificar outros tipos de imagens dado o aprendizado obtido.




Figura 3 - Arquitetura Transfer Learning.
Fonte: Wenjin Tao e et al. (2020)

A ideia por trás do transfer learning é que esses modelos pré-treinados já **aprenderam a extrair características relevantes das imagens, como bordas, texturas e padrões, que são úteis para uma variedade de tarefas de visão computacional**, sendo basicamente uma reciclagem de etapas importantes para serem aprendidas em todo tipo de imagem.




Figura 4 - Transfer Learning.
 Fonte: Sivylla Paraskevopoulou (2023)

ENTENDENDO UMA REDE DE TRANSFERÊNCIA DE APRENDIZADO: MOBILENET

Nessa aula, você irá aprender a aplicar a rede neural Mobilenet. Este modelo é baseado em convolução fatorada, ou seja, separa a convolução padrão em duas partes: a convolução em profundidade e a convolução pontual. Essa convolução profunda é chamada de Depthwise Convolution e executa uma única convolução em cada canal de cor das imagens (diferente das CNNs tradicionais), sendo assim, essa etapa filtra os canais de entrada e não os combina para criar novas features. Para gerar essas novas features, existe a camada A Pointwise Convolution, para calcular uma combinação linear da Depthwise Convolution. E claro que, logo em seguida dessas camadas, temos a função de ativação ReLU.

A segunda versão do Mobilenet, a MobilenetV2, dispõe de dois tipos de blocos (Bottleneck Blocks): Existe o bloco residual com stride = 1 e um outro bloco com stride = 2. Para cada um desses blocos, existem 3 camadas. A primeira camada é a **Pointwise Convolution** com função de ativação ReLU. A segunda camada é a **Depthwise Convolution**. E, novamente, a terceira camada é outra **Pointwise Convolution**, mas sem qualquer função não-linear ao final. Em resumo, a MobileNetV2 é uma arquitetura de rede neural convolucional eficiente que utiliza blocos de gargalo, convoluções separáveis, camadas residuais e outras técnicas para equilibrar o desempenho e a eficiência de recursos.




Figura 5 - Comparação entre a estrutura das camadas do MobilenetV1 e MobilenetV2.

Fonte: [Gabriela Alves Rodrigues \(2020\)](#)

CONFIGURANDO A MOBILENETV2

Existem vários hiperparâmetros das transfer learnings, vamos passar pelos principais e explicar sua importância na construção da rede. Para mais informações, que tal dar uma olhadinha na documentação oficial do Keras? [MobileNet](#), [MobileNetV2](#), e [MobileNetV3](#).

- **Weights:** são os pesos da rede que foram treinados pela MobileNetV2.
- **Include_top:** esse hiperparâmetro exclui a camada final de classificação da rede, ou seja, ela utiliza todo o treinamento apreendido pela MobileNetV2 no conjunto de imagens da ImageNet, mas na hora de criar os rótulos, conseguimos criar de forma personalizada, de acordo com a nossa rede neural tratada no assunto desejado.

Outro parâmetro também muito importante na transfer learning é a configuração do **layer.trainable**. Esse parâmetro é importante para manter as camadas já treinadas pela MobileNet congeladas, e em seguida, as camadas personalizadas são adicionadas para realizar a identificação do propósito de classificação da rede. Durante o treinamento, **apenas as camadas personalizadas terão seus pesos ajustados**, enquanto **as camadas pré-treinadas permanecerão inalteradas**. Para esse efeito acontecer, devemos configurar esse parâmetro como **"False"**.

Bem, podemos concluir que compreender a **aprendizagem por transferência é crucial para as pessoas cientistas de dados que se aventuram na aprendizagem profunda!** Você percebeu, ao decorrer das aulas, que as deep learnings são realmente complexas de se treinar, exige muito volume de dados, muito processamento e tempo de execução. Quando utilizamos transfer learning para reciclar features já aprendidas antes em outras imagens, o poder de ganho de tempo, performance e processamento das redes neurais é incrivelmente maior e melhor. Bom, e você deve estar se perguntando quais são esses passos aprendidos na etapa inicial das camadas de uma rede neural convolucional, certo? Podemos citar alguns exemplos:

- Convoluções de Bordas e Texturas;
- Características Complexas de Objetos;
- Hierarquia de Características;
- Representações de Alto Nível;
- Redução da Dimensionalidade.

O QUE VOCÊ VIU NESTA AULA?

Nessa aula, você aprendeu o que são as redes neurais de transferência de aprendizagem, qual é a sua utilização e benefícios para melhorar a performance de modelos de redes convolucionais.

O que achou do conteúdo? Conte-nos no Discord! Estamos disponíveis na comunidade para fazer networking, tirar dúvidas, enviar avisos e muito mais. Participe!

EMANDA

REFERÊNCIAS

ALVES, Gabriela Rodrigues. Reconhecimento de Emoções utilizando Redes Neurais Convolucionais para Auxiliar no Tratamento de Crianças com Autismo, 2020. Disponível em: <https://www.cin.ufpe.br/~tg/2020-3/TG_EC/tg_gar.pdf>. Acesso em: 27 out. 2023.

SHARMA, Pranshu. Understanding Transfer Learning for Deep Learning, 2023. Disponível em: <<https://www.analyticsvidhya.com/blog/2021/10/understanding-transfer-learning-for-deep-learning/>>. Acesso em: 27 out. 2023.

PRÖVE, Paul-Louis. MobileNetV2: Inverted Residuals and Linear Bottlenecks, 2018. Disponível em: <<https://towardsdatascience.com/mobilenetv2-inverted-residuals-and-linear-bottlenecks-8a4362f4ffd5>>. Acesso em: 27 out. 2023.

PARASKEVOPOULOU, Sivylla. Transfer Learning Made Easy, 2023. Disponível em: <<https://blogs.mathworks.com/deep-learning/2023/06/11/transfer-learning-made-easy/>>. Acesso em: 27 out. 2023.

PALAVRAS-CHAVE

Palavras-chave: Transfer Learning, redes pré-treinadas.

EMAP

The background is a dark blue field filled with numerous small, light blue dots, resembling a starry sky. Overlaid on this are several large, wavy, translucent lines in shades of blue and yellow. These lines flow from the left side towards the right, creating a sense of movement. Scattered throughout the composition are various geometric shapes: a thin vertical line, a circle containing the number '7', a small circle, an 'X' mark, a small circle, and a hexagon in the bottom right corner.

POSTECH