

ANA RAQUEL

POSTECH

DATA ANALYTICS

DEEP & REINFORCEMENT LEARNING

# AULA 05

## SUMÁRIO

|                                  |    |
|----------------------------------|----|
| O QUE VEM POR AÍ? .....          | 3  |
| HANDS ON .....                   | 4  |
| SAIBA MAIS .....                 | 5  |
| O QUE VOCÊ VIU NESTA AULA? ..... | 10 |
| REFERÊNCIAS.....                 | 11 |

EMSE

## O QUE VEM POR AÍ?

Você lembra de quando aprendeu sobre o aprendizado de máquina não supervisionado? Pois bem, agora teremos esse tipo de aprendizado em redes neurais. Basicamente, o aprendizado não supervisionado não depende de rótulos para aprender uma informação; nesse caso, os dados são criados do zero a partir de dados que são semelhantes ou têm características próximas. Em redes neurais não supervisionadas, podemos definir que as redes aprendem a criar uma imagem nova a partir de dados analisados ao longo dos neurônios. Vamos aprender um pouco mais sobre esse mundo de aprendizado não supervisionado?

## HANDS ON

Que tal ensinar uma rede neural não supervisionada a aprender cores? Nessa aula, vamos ensinar a rede a aprender cores a partir de um mapa topológico criado pela rede Self-Organizing Maps (SOM). Vamos lá?

O código desta aula você encontra no nosso Github, onde também pode [visualizar a imagem utilizada na aula](#).



## SAIBA MAIS

### ENTENDENDO AS REDES NEURAIS NÃO SUPERVISIONADAS

Falando sobre o aprendizado profundo, temos muitos tipos de redes não supervisionadas, tal como as de autoencoders, GANS (Generative Adversarial Networks), Boltzmann restritas (RBM) e também a SOMs (Self-Organizing Maps). Nessa aula, focaremos no funcionamento da rede neural SOM. A Self-Organizing Maps (SOM) foi introduzida pelo professor finlandês Teuvo Kohonen, em 1980, por isso também pode ser reconhecida como “mapa de Kohonen”. A rede SOM funciona como uma rede de mapa topológico, onde os neurônios competem entre si para trazer o melhor resultado possível, e por isso também é conhecido como aprendizado por competição. Observe a figura 1 para entender o funcionamento dessa rede.




Figura 1 - Funcionamento das redes SOMs.  
Fonte: Gisely Alves (2018)

Observe que temos alguns neurônios coloridos (inputs da rede) representados por  $x_1, x_2$ , até  $x_n$ . Cada um desses neurônios é atribuído a pesos aleatórios em  $w_{ij}$ . As cores desses neurônios **representam um mapa topológico** (podemos fazer a analogia com um mapa de cores, onde cada cor representa uma camada da rede neural), e em cada peso diferente entre as camadas é realizado uma **competição na qual todos os neurônios calculam a função discriminante** contendo características do dataset. A função discriminante é uma função matemática usada

para **separar ou discriminar entre diferentes classes ou grupos em um problema de classificação**. O objetivo de uma função discriminante é **atribuir uma instância de entrada a uma das várias classes** ou categorias **com base em suas características**. A função discriminante é representada na figura 2.

$$d_j(\mathbf{x}) = \sum_{i=1}^D (x_i - w_{ji})^2$$

Figura 2 - Função discriminante  
Fonte: Gisely Alves (2018)

Basicamente, a rede aprende o menor discriminante possível (também chamado de winner), na qual esse menor neurônio irá ativar os neurônios ao seu redor, e quanto mais distante os demais neurônios estiverem desse menor, mais complexo será para essa região de neurônios serem ativadas. Esse algoritmo é muito utilizado, por exemplo, para criar cores e absorver cores de imagens. Esse processo de ativação de neurônios é chamado de vizinhança topológica, e pode ser calculado com a função matemática da figura 3.

$$T_{j,I(\mathbf{x})} = \exp(-S_{j,I(\mathbf{x})}^2 / 2\sigma^2)$$

Figura 3 - Função de ativação de neurônios (mapa topológico).  
Fonte: Gisely Alves (2018)

Para compreender melhor o funcionamento, observe a figura 1: o neurônio bege foi iniciado de forma aleatória e os demais neurônios, que estão na cor vermelha, roxa e azul, foram inicializados posteriormente. Quanto mais entradas, mais cores e ativações seriam realizadas. Perceba que os que estão em azul estão bem distantes do ponto bege, e isso se deve pelo fato de estar muito distante do neurônio winner. Os pesos da rede são movidos de acordo com a vizinhança topológica, e esse efeito faz com que o neurônio winner “puxe” outros neurônios, conforme podemos visualizar na figura 4.




Figura 4 - Mapa de ativação de cores.  
Fonte: Gisely Alves – Medium (2018)

Podemos pensar que esse tipo de algoritmo realiza uma redução da dimensionalidade dos dados, visto que ele aprende a criar representações de baixa dimensão (normalmente bidimensional) do espaço de entrada das amostras de treinamento. Perceba que, nessa rede neural, não vamos aplicar o processo de retropropagação com descida do gradiente, a ideia aqui é utilizar a função de vizinhança para preservar as propriedades topológicas.

#### **Etapas do funcionamento do algoritmo:**

- 1º passo: os pesos são inicializados.
- 2º passo: um vetor é escolhido de forma aleatória do conjunto de dados.
- 3º passo: cada neurônio é examinado para calcular os pesos e analisar quais são mais parecidos para criar a vizinhança, ou seja, quais são mais próximos com o winner (menor neurônio).
- 4º passo: ao calcular a vizinhança, a quantidade de neurônios vai diminuindo com o decorrer do processamento da rede.
- 5º passo: o peso vencedor é compensado por ser mais próximo com o vetor de amostra. Os vizinhos de amostra também são atribuídos à semelhança dada à similaridade com o vetor de amostra (mapa topológico).
- 6º passo: a etapa 2 é repetida N vezes para N iterações do algoritmo.

Falando do cálculo da distância entre os pesos para encontrar a vizinhança, podemos pensar, por exemplo, na distância euclidiana. A técnica de encontrar a vizinhança é conhecida como **Best Matching Unit**.






Figura 5 - Rede Self-Organizing Maps  
 Fonte: Gifa Delyani Nursyafitri (2019)

## APLICAÇÕES DAS SOMS

A rede SOM é fascinante e poderosa no campo do aprendizado de máquina, sendo capaz de revelar padrões com eficiência, visualizar dados complexos e realizar tarefas de agrupamento sem a necessidade de conjuntos de dados rotulados. Podemos citar muitas aplicações dessa rede, tais quais:

- Visualização de dados: a rede auxilia na compreensão de dados complexos de alta dimensão, mapeando assim uma grade 2D.
- Clustering: a função de vizinhança basicamente funciona como uma tarefa de clustering, particionando dados em grupos semelhantes com base na similaridade.
- Feature Extraction e redução de dimensionalidade: essa rede pode ser utilizada como uma etapa de pré-processamento de dados com o objetivo de reduzir a dimensionalidade e melhorar o desempenho dos algoritmos.
- Detecção de anomalias: essa rede pode identificar anomalias ou valores discrepantes que se desviam significativamente das representações apreendidas.



## CONFIGURANDO UMA REDE SELF-ORGANIZING MAPS (SOM)

No Python, temos a biblioteca MiniSom para realizar esse tipo de tarefa de mapas topológicos, e existem alguns parâmetros importantes quando construímos a rede neural, como:

- **x**: número de linhas de neurônios da dimensão do mapa topológico a ser criado pela SOM.
- **y**: número de colunas de neurônios da dimensão do mapa topológico a ser criado pela SOM.
- **input\_len**: o número de componentes dos dados de entrada.
- **sigma**: o valor inicial do raio de vizinhança. Controla a extensão da vizinhança dos neurônios vizinhos durante o treinamento.
- **learning\_rate**: taxa de aprendizado da rede.
- **neighborhood\_function**: a função de vizinhança a ser usada durante o treinamento.
- **topology**: a topologia do mapa da SOM. Pode ser "rectangular" (grade retangular) ou "hexagonal" (grade hexagonal).

## O QUE VOCÊ VIU NESTA AULA?

Nessa aula, demos mais um passo na nossa evolução no conhecimento de deep learning, conhecendo o mundo das redes não supervisionadas e entendendo o funcionamento da arquitetura de uma das redes mais famosas, a Self-Organizing Maps (SOM).

O que achou do conteúdo? Conte-nos no Discord! Estamos disponíveis na comunidade para fazer networking, tirar dúvidas, enviar avisos e muito mais. Participe!

EMAND

## REFERÊNCIAS

NURSYAFITRI, Gifa Delyani. Self organizing maps. Disponível em: <<https://medium.com/@abhinavr8/self-organizing-maps-ff5853a118d4>>. Acesso: 31 out. 2023.

ALVES, Gizely. Descobrindo SOM, uma rede neural com aprendizado não supervisionado. Disponível em: <<https://medium.com/infosimples-br/descobrindo-som-uma-rede-neural-com-aprendizado-n%C3%A3o-supervisionado-f22bc1e55eca>>. Acesso: 31 out. 2023.

## **PALAVRAS-CHAVE**

**Palavras-chave:** SOM, Self-Organizing Maps, MiniSom.

EMSE

The background is a dark blue field filled with numerous small, light blue dots, resembling a starry sky. Overlaid on this are several large, wavy, translucent lines in shades of blue and yellow. These lines flow from the left side towards the right, creating a sense of movement. Scattered throughout the composition are various geometric shapes: a thin vertical line, a circle containing the number '7', a small circle, an 'X' mark, a small circle, and a hexagon in the bottom right corner.

POSTECH