

ANA RAQUEL

POSTECH

DATA ANALYTICS

DEEP & REINFORCEMENT LEARNING

AULA 06

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	10
REFERÊNCIAS.....	11

EMSE

O QUE VEM POR AÍ?

Ainda no universo de redes não supervisionadas, chegou o momento de aprender Redes Adversárias Generativas (GANs)! Essas redes são consideradas generativas porque elas criam novos dados, e adversárias porque são arquiteturas de redes neurais profundas compostas por duas redes colocadas uma contra a outra. Nesta aula, você aprenderá a sua arquitetura e como funciona essa rede criativa! Vamos lá?

EMAN

HANDS ON

Vamos criar a sua primeira rede neural adversária? Utilizaremos, nesta aula, [a base de dados](#) do famoso conjunto de dados de dígitos escrito às mãos, o MNIST.

O código desta aula você encontra no [github da nossa turma](#).

EMSE

SAIBA MAIS

ENTENDENDO AS REDES ADVERSÁRIAS GENERATIVAS (GANS)

As redes Adversárias Generativas possuem um grande potencial, pois são capazes de gerar novos dados a partir de um conjunto de dados treinados. Podemos treinar essa rede para criar, por exemplo, novas imagens, músicas, falas, prosas, tratar resoluções de imagens e vídeos e muito mais. Uma das suas utilidades também pode ser criar novas imagens a partir de um conjunto de dados real para criar mais amostras de dados ao treinar uma rede neural convolucional. Veja na figura 1 e 2 algumas imagens geradas por rede adversária generativa.




Figura 1 - Imagem gerada por uma rede GAN, criada a partir do texto “Teddy bears trabalhando em pesquisa de inteligência artificial debaixo d’água com tecnologia dos anos 90”.

Fonte: Didática Tech (s.d.)




Figura 2 - Dois dos nus gerados por GANs. Imagens de [Robbie Barrat](#)
Fonte: Deep Learning Book (s.d.)

As redes GANs podem criar dados fakes, assim como validar a veracidade de dados. A GANs também é muito utilizada para recriar partes de imagens, como por exemplo, se temos uma imagem de um cachorro pela metade, ela tem o poder de completá-la. Falando ainda do uso da rede em imagens, a Pixar, uma grande empresa que trabalha com animações, utiliza muito as redes GANs para aumento de resolução de imagens. Para quem não conhece as redes Adversárias Generativas, até parece mágica, não é mesmo? Mas nessa aula desvendaremos alguns truques da GANs, mergulhando na matemática e modelagem por trás desses modelos.

ENTENDENDO O FUNCIONAMENTO DA GANS

Você aprendeu, na aula de redes não supervisionadas, que algoritmos discriminativos tentam criar classes ou grupos a partir de dados de entrada, ou seja, mapeiam recursos para criar rótulos utilizando correlação. Os algoritmos generativos fazem justamente o oposto, eles tentam prever os recursos (dados) com um determinado rótulo. Por exemplo, se um e-mail é classificado como spam, qual é a probabilidade de palavras que formam esse e-mail serem spam? Os algoritmos discriminativos se preocupam com a correlação entre x e y , modelos generativos se preocupam em como você irá obter x .

Basicamente, as GANs são compostas por duas redes, a **geradora** e a **discriminante**. São chamadas de adversárias, porque elas tentam “jogar” uma com a

outra o tempo todo. A rede geradora tenta enganar a rede discriminante gerando dados fakes semelhantes aos dados reais.




Figura 3 - Arquitetura redes GANs.
Fonte: Deep Learning Book (s.d.)

Utilizaremos como exemplo a clássica base de dígitos gerados à mão do MNIST. O objetivo da rede discriminante, aqui, é reconhecer que os dígitos gerados à mão são os mais próximos possíveis dos verdadeiros números. A rede geradora tenta criar novas imagens fakes com a esperança de torná-las autênticas também (mesmo sendo falsas). O funcionamento da rede consiste nas seguintes etapas: o gerador considera números aleatórios e retornam uma imagem (ou seja, cria uma imagem fake), a imagem gerada é inserida no discriminador ao lado do fluxo de imagens verdadeiras geradas, o discriminador obtém imagens reais e falsas, retornando a probabilidade e realizando previsões de imagens falsas geradas pela rede generativa.




Figura 4 - Funcionamento de uma rede GAN.
Fonte: Deep Learning Book (s.d.)

Podemos dizer que a rede geradora é uma rede neural convolucional inversa. Enquanto um classificador padrão reduz a amostragem para produzir a probabilidade, o gerador pega um vetor de ruído aleatório e faz o upsample (operação usada para aumentar o tamanho espacial de um tensor de saída) para uma imagem. O primeiro joga fora os dados por meio de técnicas de downsampling (processo de redução do tamanho espacial (resolução) de um tensor de saída) e o segundo gera novos dados. Ambas as redes (geradora e discriminante) utilizam a função de custo para tentar minimizar o erro. À medida que o discriminador muda seu comportamento, o gerador também muda e vice-versa.




Figura 5 - Exemplo funcionamento rede GANs
Fonte: Laura Martinez Molera (2021)

A MATEMÁTICA DE GANS

O Discriminador e o Gerador jogam um jogo minimax para dois jogadores, com a função de valor $V(G, D)$. Portanto, a função Objetivo Minimax é:

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

Figura 6 - Função Minimax.
Fonte: Shweta Goyal (2019)

A função $D()$ nos fornece uma estimativa da probabilidade de que a amostra que lhe foi apresentada seja realmente um dado de treinamento $\mathbf{x}$. No caso do Gerador, o nosso objetivo é minimizar a expressão $\log(1 - D(G(\mathbf{z})))$, o que significa que, quando o valor de $D(G(\mathbf{z}))$ for alto, isso indica que D está quase certo de que $G(\mathbf{z})$ é igual a $\mathbf{x}$. Isso, por sua vez, faz com que $1 - D(G(\mathbf{z}))$ seja muito baixo, e nosso objetivo é reduzi-lo ainda mais.

Para o Discriminador, queremos maximizar tanto $D(X)$ quanto $1 - D(G(z))$. Em outras palavras, queremos que o Discriminador seja o mais competente possível em identificar dados reais (X) como reais e dados gerados ($G(z)$) como falsos. Assim, quando o Discriminador está em seu estado ideal, a probabilidade $D(X)$ deve ser 0,5, o que significa que ele não pode distinguir com confiança entre as duas classes.

No entanto, o nosso objetivo final é treinar o Gerador G de tal forma que ele produza resultados que confunda completamente o Discriminador D . Queremos que o Discriminador não seja capaz de discernir entre as amostras reais (X) e as amostras geradas ($G(z)$), o que é um indicador de que o Gerador melhorou e produz resultados cada vez mais realistas.

O QUE VOCÊ VIU NESTA AULA?

Nessa aula, você aprendeu como são complexas as redes neurais adversárias e como funciona a sua arquitetura por trás da mágica.

O que achou do conteúdo? Conte-nos no Discord! Estamos disponíveis na comunidade para fazer networking, tirar dúvidas, enviar avisos e muito mais. Participe!

EMANIP

REFERÊNCIAS

Deep Learning Book. Introdução às Redes Adversárias Generativas (GANs – Generative Adversarial Networks), [s.d.]. Disponível em: <https://www.deeplearningbook.com.br/introducao-as-redes-adversarias-generativas-gans-generative-adversarial-networks/>. Acesso: 31 out. 2023.

Didática Tech. O que são GAN's – Redes adversárias generativas, [s.d.]. Disponível em: <https://didatica.tech/introducao-a-gans-redes-adversarias-generativas/>. Acesso em: 31 out. 2023.

GOODFELLOW, Ian et al. Generative adversarial nets. Advances in neural information processing systems, 2014. Disponível em: <https://arxiv.org/pdf/1406.2661.pdf>. Acesso: 31 out. 2023.

GOYAL, Shweta. GANs — A Brief Introduction to Generative Adversarial Networks, 2019. Disponível em: <https://medium.com/analytics-vidhya/gans-a-brief-introduction-to-generative-adversarial-networks-f06216c7200e>. Acesso: 31 out. 2023.

MOLERA, Laura Martinez. Synthetic Image Generation using GANs. Disponível em: <https://blogs.mathworks.com/deep-learning/2021/12/02/synthetic-image-generation-using-gans/>. Acesso: 31 out. 2023.

PALAVRAS-CHAVE

Palavras-chave: GANs, rede geradora, rede discriminante.

EMENDAS

The background is a dark blue field filled with numerous small, light blue dots, resembling a starry sky. Overlaid on this are several large, wavy, translucent lines in shades of blue and yellow. These lines flow from the left side towards the right, creating a sense of movement. Scattered throughout the composition are various geometric shapes: a thin vertical line, a circle containing the number '7', a small circle, an 'X' mark, a small circle, and a hexagon in the bottom right corner.

POSTECH